CASSONI — AUTOMATIZACIÓN SEO

Pipeline de optimización SEO para catálogo de productos de lujo

Sistema automatizado que extrae la ficha completa de productos desde WooCommerce, identifica keywords de alto volumen mediante Search Console y DataForSEO, y las incorpora en H1 y descripciones con validación por LLM.

(01) — RESUMEN EJECUTIVO

Qué construimos.

Objetivo

Cassoni opera una tienda WooCommerce con **11.000 productos** de mobiliario de lujo. Cada producto tiene un H1 y una descripción larga ya redactados. El pipeline toma una lista de URLs, extrae la ficha completa vía API, busca keywords de alto volumen específicas del nicho, y las incorpora quirúrgicamente en los textos existentes sin romper el tono ni la redacción original. Todo queda registrado en una base de trazabilidad.

11.000

Productos

Catálogo completo de muebles de lujo en WooCommerce.

~$346 USD

Costo Total Asociado

DataForSEO (volumen + SERP) + Gemini Flash. Consumo real estimado — costo asociado al proyecto.

2

Campos Optimizados

H1 (1 keyword principal) + Descripción larga (hasta 9 keywords secundarias).

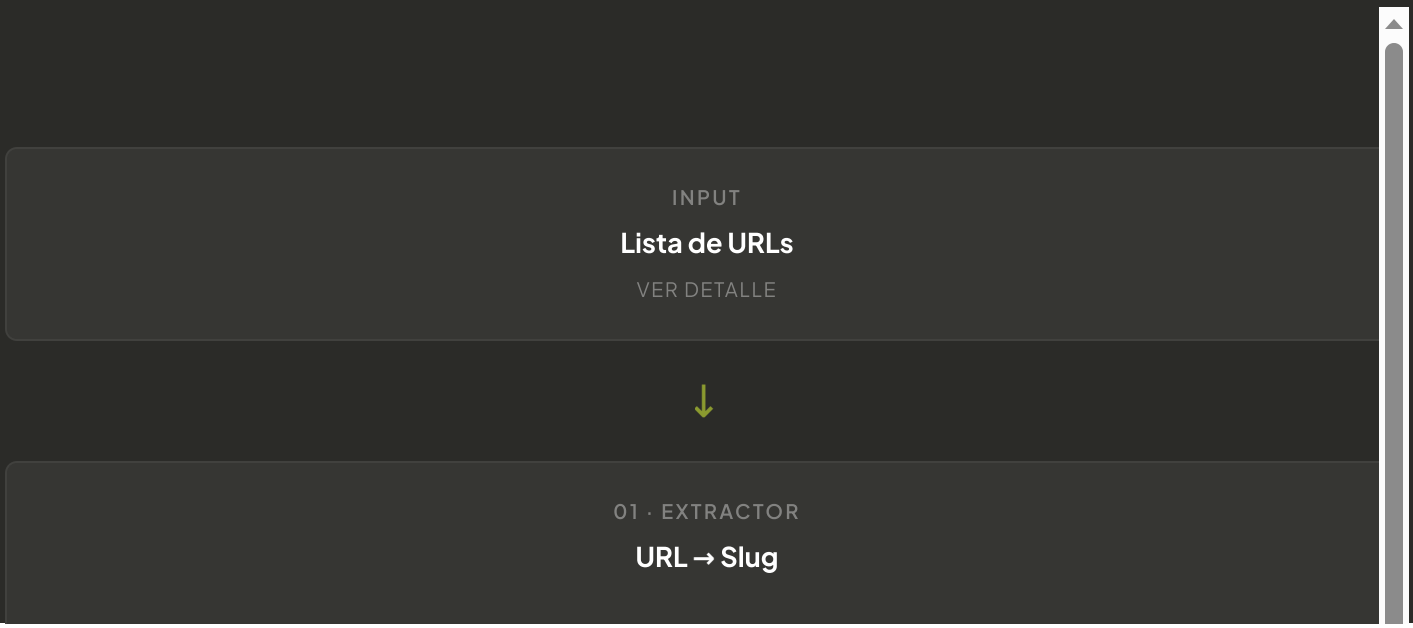
7

Componentes

Extractor, WooCommerce, GSC, DataForSEO, LLM editor, Validador, DB de trazabilidad.

(02) — ARQUITECTURA

Flujo del pipeline.



VER DETALLE

↓

02 · WOOCOMMERCE

Ficha JSON Completa

VER DETALLE

↓

03 · GSC API

Top 10 Keywords

VER DETALLE

↓

04 · DATAFORSEO

Filtra × Volumen

VER DETALLE

↓

05 · LLM

Edita H1 + Desc

VER DETALLE

↓

06 · VALIDADOR

Control de Calidad

VER DETALLE

↓

07 · DB

Trazabilidad

VER DETALLE

(03) — COMPONENTES

Cada pieza en detalle.

01 · Extractor de URL a Slug

Script Python que procesa cualquier URL de WooCommerce y determina si es producto, categoría o etiqueta. Soporta múltiples idiomas (español, inglés, portugués, francés), URLs con query params, pretty permalinks, y estructuras custom. Si no puede determinar el tipo, lo reporta explícitamente.

Endpoint: `/wp-json/wc/v3/products?slug={slug}` · Auth: Consumer Key + Secret (Basic)

02 · WooCommerce API — Ficha Completa

Con el slug, consulta la REST API de WooCommerce y obtiene el objeto JSON completo: nombre, descripción (HTML), short_description, precio, SKU, categorías, tags, imágenes, atributos, variaciones, meta_data, dimensiones, stock, y más. Para productos variables, también extrae todas las variaciones con sus precios y atributos.

Campos clave: `name` (H1 actual) · `description` (HTML) · `permalink` · `categories[]`

03 · Google Search Console API

Para cada producto, consulta las **top 10 keywords** por las que esa URL recibió impresiones en los **últimos 12 meses**. Usa OAuth 2.0 para autenticarse contra la propiedad de Cassoni en Search Console. **La API permite hasta 50.000 filas de datos por día**, más que suficiente para procesar los 11.000 productos del catálogo.

Costo: $0 (gratuito) · Límite: 50.000 filas/día · Endpoint: `/webmasters/v3/sites/{site}/searchAnalytics/query`

04 · DataForSEO — Filtro por Volumen de Búsqueda (Técnica de Bulking)

GSC devuelve 10 keywords por producto → **~110.000 keywords total** (11.000 productos × 10). Pero muchas se repiten entre productos similares.

¿Por qué no son 110.000 keywords únicas?
Imaginá 5 sofás distintos en el catálogo. GSC devuelve para cada uno:
Sofá A: "sofá de lujo", "sofá milano", "sofá cuero negro", "comprar sofá", "cassoni", ...
Sofá B: "sofá de lujo" 🔁, "sofá parís", "sofá terciopelo", "comprar sofá" 🔁, "cassoni" 🔁, ...
Sofá C: "sofá de lujo" 🔁, "muebles de diseño", "sillones modernos", "cassoni" 🔁, ...

Patrón: términos de categoría y marca se repiten en decenas o cientos de URLs. Solo los long-tail específicos ("sofá milano cuero negro") son realmente únicos.
Resultado: de 110.000 keywords, tras deduplicar quedan entre 20.000 y 40.000 únicas (~65–80% de solapamiento). El número exacto depende de la diversidad del catálogo y se conocerá al procesar los datos reales de Cassoni.

Se realiza una **deduplicación con trazabilidad**: cada keyword única mantiene una lista de las URLs de origen, para poder re-mapear los volúmenes a cada producto después del bulk.

Técnica de bulking: DataForSEO permite enviar hasta 1.000 keywords en un solo request HTTP. La API cobra **$0,0095 por keyword** (validado con datos reales: 19 keywords consumieron $0,18). El bulking no reduce el costo por keyword, pero sí la velocidad: en lugar de 30.000 llamadas individuales, consolidamos todo en 30 requests de 1.000. La API devuelve los volúmenes en el **mismo orden** del array de entrada, lo que permite re-mapear cada volumen a su keyword y de vuelta a los productos de origen.
Peor caso (40.000 únicas): $380.
Caso esperado (30.000 únicas): $285.
Es el componente más caro del proyecto y el costo dominante del pipeline.

En el pipeline, para cada producto se filtran **hasta 10 keywords** entre las que devolvió GSC, descartando nombres de marca y términos irrelevantes para mobiliario de lujo. Las que quedan se incorporan en H1 (la más descriptiva) y descripción (el resto).

Endpoint: `/v3/keywords_data/google_ads/search_volume/live` · **Flujo:** GSC por URL → keyword + URL mapping → deduplicar preservando origen → DataForSEO bulk (1.000/req) → resultados mapeados de vuelta a cada producto

05 · LLM Editor — Optimización de H1 y Descripción

El LLM recibe el H1 actual y la descripción larga existente, más las keywords seleccionadas. Debe:

- Elegir la **keyword más descriptiva** del producto para el H1
- Insertarla de forma **natural y coherente** sin forzar
- Incorporar **las keywords restantes en la descripción larga**

- Preservar el **tono de lujo** de Cassoni
- No repetir conceptos que ya estaban en el texto original
- Mantener el HTML y formato existentes

Modelo sugerido: Gemini 2.5 Flash (~$15,40 para 11K productos como editor). Ver comparativa completa en sección 09.

06 · Agente Validador

Un segundo LLM —o el mismo con un prompt de validación— revisa cada output: coherencia del texto, tono de lujo preservado, keywords efectivamente incorporadas, ausencia de repetición, y que el H1 siga siendo descriptivo del producto. Si detecta problemas, rebota el texto al editor para una segunda pasada.

Ritmo: ~50 productos/día procesados. Cada tanto, el equipo SEO revisa manualmente.

07 · Base de Datos de Trazabilidad

Cada producto procesado registra: URL, slug, keywords obtenidas de GSC, volumen de cada una vía DataForSEO, cuáles se seleccionaron y por qué, dónde se insertaron (H1 o descripción), el texto antes y después, y el resultado de la validación. Esto permite auditoría completa, iteración sobre decisiones pasadas, y demostración de impacto SEO.

(04) — COSTOS ASOCIADOS

Proyección para 11.000 productos.

Económico | Recomendado | Premium | Calidad-Precio | Máxima calidad

COMPONENTE	VOLUMEN	COSTO UNITARIO	TOTAL
Google Search Console API	11.000 consultas (top 10	Gratuito	$0,00

COMPONENTE	VOLUMEN	COSTO UNITARIO	TOTAL
	keywords c/u)		
DataForSEO — search volume	20.000–40.000 keywords únicas	$0,0095 / keyword (validado: 19 kw = $0,18)	$190–$380
DataForSEO — SERP analysis	3 keywords × 11.000 productos = 33.000 (con dedup: ~10.000–15.000 únicas)	$0,002 / keyword	$20–$30
LLM Editor (Gemini Flash)	11.000 productos × ~500 tok in + ~500 tok out c/u	$0,30/$2,50 / 1M tok	$15,40
LLM Validador (Gemini Flash)	11.000 productos × ~500 tok in + ~500 tok out c/u	$0,30/$2,50 / 1M tok	$15,40
Infraestructura (VPS)	Cloud dedicado — IP ya autorizada en	$0 marginal	$0,00

COMPONENTE	VOLUMEN	COSTO UNITARIO	TOTAL
	Cloudflare allowlist de Cassoni		

Total estimado — Catálogo completo (Gemini Flash) **≈ $241–$441 USD · esperado ~$346**

Proyección ilustrativa

Cifras no vinculantes basadas en precios públicos de cada API a julio 2026. DataForSEO es el costo dominante: search volume $0,0095/kw + SERP analysis $0,002/kw. Con Gemini Flash para edición y validación: **~$241–$441**. Con setup híbrido (Flash editor + Claude validador): **~$324–$524**. Ver sección 09 para el desglose completo por modelo.

Los costos de servicios y APIs pueden variar a lo largo del proceso: DataForSEO, Google y los proveedores de LLM ajustan sus tarifas periódicamente, y el volumen real de keywords únicas puede diferir del estimado. La base de trazabilidad registra el costo real por producto en cada ejecución, lo que permite detectar desvíos y recalibrar la proyección con datos medidos, no supuestos.

🖩 Cálculo del costo DataForSEO ($315 en caso esperado)

Search Volume: GSC devuelve 10 keywords por URL → 110.000 total → tras deduplicar quedan ~30.000 únicas. 30.000 × **$0,0095** (validado: 19 kw = $0,18) = **$285**
SERP Analysis: de las keywords filtradas por volumen, tomamos hasta 3 por producto → 33.000 total → tras deduplicar quedan ~15.000 únicas. 15.000 × **$0,002** = **$30**
Total DataForSEO = $285 + $30 = $315 en el caso esperado. Varía entre $210 y $410 según la tasa de duplicación real del catálogo Cassoni.

🏆 ¿Por qué "Recomendado"?

Gemini Flash procesa el 100% de productos a costo mínimo ($15,40). Una vez por semana, se toma una muestra de 20–30 productos y se re-evalúa con Claude para detectar degradación de calidad o desvíos de tono. Si el muestreo pasa limpio 3 semanas seguidas,

se espacia. **Costo adicional: ~$22/mes en Claude.** Es el mejor equilibrio: velocidad y bajo costo del Flash con la supervisión periódica del Claude.

Rango real (20K–40K keywords)

Económico: $241–$441
Recomendado: $263–$463
Máxima calidad: $408–$608

Costo por producto

Económico: ~$0,031 / producto
Recomendado: ~$0,033 / producto
Máxima calidad: ~$0,047 / producto

(05) — IMPLEMENTACIÓN

Fases del proyecto.

Fase 1 — Setup

Verificar credenciales de WooCommerce API (ya disponibles vía equipo SEO). Validar acceso OAuth a Google Search Console (ya configurado). Activar cuenta DataForSEO (plan Light ~$50/mes). Script extractor de URL → slug.

Fase 2 — Extracción (Staging)

Conectar WooCommerce API contra el **sitio de staging** de Cassoni (idéntico a producción). Procesar un lote piloto de 10–20 productos sin riesgo. Validar que la ficha JSON contiene todos los campos necesarios. Script de extracción de GSC para top 10 keywords.

Fase 3 — Keywords

Integrar DataForSEO para filtrar volumen. Afinar la lógica de descarte (marcas, términos genéricos, keywords no relevantes para lujo). Definir criterio de selección de la keyword principal para H1.

Fase 4 — LLM + Validación

Integrar el LLM editor (Gemini Flash) y el agente validador (Claude Sonnet). Nosotros definimos y ajustamos los prompts junto con el equipo de Cassoni; conectamos las APIs y armamos la interfaz para que puedan iterar sin tocar código. Procesar lote piloto con revisión del equipo SEO.

Fase 5 — Escala + Cron

DB de trazabilidad. Procesamiento del catálogo completo (11.000 productos) desde staging, con migración controlada a producción cuando esté validado. Cron en **horario de oficina con intervalos variables** (9–18 horario local, pausas aleatorias entre requests) para evitar que Google detecte automatización y penalice el sitio.

(06) — CRON

Ejecución anti-bot.

Por qué en horario de oficina con intervalos variables

Google detecta patrones de actualización masiva de contenido y puede interpretarlos como manipulación automatizada de SEO, lo que deriva en penalizaciones en el ranking. Un flujo constante de 11.000 productos editados en secuencia a las 3 AM es una firma clara de automatización. En cambio, ediciones espaciadas aleatoriamente durante el horario comercial (9:00–18:00, horario local) son indistinguibles del ritmo de trabajo de un equipo editorial humano. El objetivo es que Google vea un sitio con contenido que mejora orgánicamente, no un sitio siendo optimizado por un bot.

Ventana horaria

Lunes a viernes, 9:00–18:00 (horario local).
Sin ejecución fines de semana ni madrugada.
Si un producto queda pendiente, se retoma al día siguiente.

Intervalos variables

Tiempo aleatorio entre productos: **30s–5min**.
Simula el ritmo de un redactor humano: a veces edita rápido, a veces se toma un café entre producto y producto.
Distribución no uniforme para evitar patrones detectables.

Volumen diario

Ritmo fijo: **50 productos/día**.
Catálogo completo (11.000) en **~220 días hábiles**.

Implementación

Cron con **agente supervisor** integrado.
`random.uniform(30, 300)` segundos entre productos.
Solo ejecuta en horario hábil (9–18 horario local, lun-vie).
Google ve ediciones a ritmo humano, no un bot.

(07) — STACK

Tecnologías utilizadas.

Backend

Python 3.11+
Scripts modulares: extractor de slug, cliente WooCommerce, cliente GSC, cliente DataForSEO, orquestador del pipeline, validador.

APIs Externas

WooCommerce REST API v3 — ficha de producto
Google Search Console API — keywords + impresiones
DataForSEO — search volume + filtrado

LLM

Gemini 2.5 Flash — edición (bajo costo, alta velocidad)
Claude 3.5 Sonnet — validación (mejor razonamiento)
Alternativas: DeepSeek V4, GPT-4o. Ver comparativa en sección 09.

Base de Datos

PostgreSQL — trazabilidad de keywords, versiones de texto antes/después, logs de validación.

Infraestructura

Cloud dedicado — IP ya autorizada en Cloudflare allowlist de Cassoni (sin bloqueos)
Staging — sitio idéntico al de producción para pruebas seguras
GitHub — control de versiones
Cron variable — ejecución en horario de oficina simulando tráfico humano

(08) — POR QUÉ PYTHON

Por qué Python + Cron y no n8n.

Cassoni ya tiene un workflow de SEO en n8n (33 nodos, 119K imágenes procesadas). Para aquel proyecto, n8n fue la herramienta correcta: un flujo lineal de transformación de datos. Este proyecto es distinto. Estos son los motivos técnicos.

1. Esto no es un workflow — es un scheduler

n8n ejecuta workflows: disparador → pasos secuenciales → fin. Este proyecto necesita un **planificador que corra durante meses**, con pausas aleatorias, ventanas horarias, reanudaciones automáticas, y rate limiting coordinado entre 3 APIs distintas. Eso es un cron con lógica de scheduling, no un workflow.

2. Bulking: acumular antes de enviar

La técnica de bulking de DataForSEO requiere **acumular keywords de múltiples productos** antes de hacer un solo request de 1.000. n8n procesa items de a uno; no tiene un mecanismo nativo para "juntá 1.000 y después mandá". En Python es un array y un contador.

3. Trazabilidad con SQL real

Cada decisión del pipeline queda registrada en PostgreSQL: qué keyword, qué URL, qué volumen tenía, por qué se eligió, dónde se insertó, texto antes y después, resultado de la validación. n8n puede loguear en JSON, pero consultar "mostrame todas las keywords descartadas por ser marcas" requiere SQL.

4. Agente supervisor 24/7

El pipeline no corre solo: un **agente LLM monitorea cada ejecución**. Si algo falla —GSC sin datos, DataForSEO timeout, LLM responde incoherencias— envía un correo al equipo con el diagnóstico exacto: qué producto, qué paso falló, por qué, y si ya se salteó automáticamente. n8n puede disparar un webhook, pero no redactar un email diciendo *"el producto #237 no tiene datos en GSC, es esperable para productos nuevos, lo salteé y seguí"*.

5. Versionado con git

Cada cambio en la lógica del pipeline es un commit: qué se modificó y por qué. Si el equipo de SEO dice "volvé a la versión de la semana pasada que funcionaba mejor", es **un git revert**. n8n tiene historial de versiones pero está atado a la UI y no sobrevive a migraciones o cambios de entorno.

6. Evolución sin límites de canvas

Cuando el equipo de SEO pida "agreguemos otra fuente de keywords" o "cambiemos el criterio de selección de 3 a 5", en Python es **código nuevo + deploy**. En n8n es arrastrar nodos en un canvas que ya tiene 33, con el riesgo constante de romper una conexión invisible. A escala de 11.000 productos y meses de operación, el código es más mantenible que un diagrama.

n8n fue la herramienta correcta para el proyecto anterior

El workflow de 33 nodos para generar meta descriptions de 119K imágenes era un flujo de transformación: imagen → clasificación → generación → validación. Ahí n8n brilló porque cada item sigue el mismo camino lineal. Este proyecto es un scheduler de largo plazo con bulking, rate limiting coordinado, y una DB relacional de trazabilidad. Para eso, Python + PostgreSQL + Cron es la infraestructura correcta.

(09) — LLMS

Comparativa de modelos.

Costos calculados para 11.000 productos: ~5.5M tokens input + ~5.5M tokens output (editor). El validador duplica el costo. Precios a julio 2026. Cifras no vinculantes.

MODELO	PROVIDER	INPUT / 1M TOK	OUTPUT / 1M TOK	EDITOR	EDITOR + VALIDADOR
Gemini 2.5 Flash	Google	$0,30	$2,50	$15,40	$30,80
GPT-4o Mini	OpenAI	$0,15	$0,60	$4,13	$8,26
DeepSeek V4 Pro	API oficial	$0,435	$0,87	$7,18	$14,36
Gemini 2.5 Pro	Google	$1,25	$10,00	$61,88	$123,76

MODELO	PROVIDER	INPUT / 1M TOK	OUTPUT / 1M TOK	EDITOR	EDITOR + VALIDADOR
GPT-4o	OpenAI	$2,50	$10,00	$68,75	$137,50
Claude 3.5 Sonnet	Anthropic	$3,00	$15,00	$99,00	$198,00
Claude Opus 4	**Anthropic**	**$15,00**	**$75,00**	**$495,00**	**$990,00**

🏆 Recomendado: Gemini 2.5 Flash

Mejor relación costo/calidad. $30,80 para el catálogo completo con validador. Google infrastructure, latencia mínima. Ideal para la fase de edición por volumen.

Validación: Claude 3.5 Sonnet

Para el agente validador, donde la calidad del output es crítica, Claude ofrece el mejor razonamiento para detectar inconsistencias. $99 para el catálogo completo como validador (una pasada por producto).

Setup híbrido óptimo

Editor → Gemini 2.5 Flash: $15,40 (barato, rápido).
Validador → Claude 3.5 Sonnet: $99,00 (mejor razonamiento).
Total híbrido: ~$114 en LLMs para 11.000 productos (sin contar DataForSEO). Lo mejor de ambos mundos: costo bajo en edición masiva + calidad Claude en validación.

(10) — ROADMAP

Estimación de desarrollo.

La estructura de datos de WooCommerce de Cassoni ya la conocemos (procesamos 7.800 productos en el proyecto anterior de SEO). Credenciales ya disponibles. **Las 4 APIs involucradas están maduras, tienen librerías Python listas para usar, documentación exhaustiva y ejemplos de código funcionales.**

Validación de APIs

WooCommerce: wrapper Python oficial (`wc-api-python`). Fetch de producto en 5 líneas.
GSC API: Google provee guías completas con código Python listo para copiar. Método `searchanalytics.query()` con filtro por `page` para extraer keywords por URL. Autenticación vía OAuth2 o service account.
DataForSEO: endpoint bulk de 1.000 keywords/request. Basic Auth (base64). Documentación con ejemplos en curl y Python.
LLMs (Gemini, Claude, GPT): todos usan endpoints OpenAI-compatible. Mismo formato, mismo cliente HTTP.
Conclusión: las 4 APIs se conectan en horas, no en días. El trabajo real está en el orquestador, la trazabilidad y los fallbacks — no en la integración.

Día 3 — Pipeline completo procesando URLs reales

Día 1: credenciales + WooCommerce (fetch de ficha desde staging) + **schema DB trazabilidad** (qué keywords, qué URL, qué volúmenes, qué decisión).
Día 2: GSC (OAuth + top 10 keywords) + DataForSEO (volumen) + **cron variable** (9–18 horario local, intervalos aleatorios 30s–5min).
Día 3: conexión LLM + orquestador + validador. **El pipeline procesa URLs reales, registra cada decisión en la DB, y corre en horario de oficina con timing humano.**

Días 4–7 — Fallbacks, control de calidad, primer lote

Fallbacks: qué pasa si GSC no tiene datos para esa URL, si DataForSEO falla, si el LLM devuelve texto inválido. Degradación elegante, reintentos, logs.
Primer lote real: procesar 10 productos en staging, entregar resultados al equipo de SEO para validación de contenido.
Documentación: guía de operación, cómo leer la trazabilidad, cómo cambiar prompts sin tocar código.

Día 3

Pipeline completo

APIs + DB trazabilidad + cron variable + validador. Procesando URLs reales.

Día 7

Lote entregado

10 productos optimizados + fallbacks + documentación.

Después de semana 1

Optimización opcional

Bulking DataForSEO. No bloquea: el sistema ya está produciendo.

Total: 1 semana para el pipeline completo con trazabilidad, cron variable, fallbacks, y primer lote de 10 productos. A partir de ahí corre solo a 50/día. La trazabilidad registra desde el primer producto: qué keywords se seleccionaron, por qué (volumen), dónde se insertaron (H1/descripción), texto antes y después.

(11) — PRÓXIMOS PASOS

Para arrancar.

Dependencias inmediatas

1. Activar cuenta en **DataForSEO** (plan Light, ~$50/mes).
2. Coordinar acceso al **sitio de staging** de Cassoni para las pruebas.
3. Definir el **lote piloto** de 10–20 productos para la primera validación.
4. El equipo SEO de Dendra prepara los **prompts iniciales** del LLM, con revisión del equipo de Cassoni.

CASSONI × DENDRA CREATIVE AGENCY · JULIO 2026 · CONFIDENCIAL